

Объяснимая математическая модель геометрической живости для защиты лицевой биометрии от плоских атак

Куанышбеков Даулет · Молдағалиева Асия

10А класс · направление: математика · [указать учебное заведение] · научный руководитель: [указать научного руководителя]

1. Задача

Системы распознавания лица обманывает простейшая атака: камере показывают не человека, а его фотографию — распечатанную или с экрана телефона. Такие атаки называют **плоскими**: носитель изображения есть плоскость.

Цель работы. Построить интерпретируемую математическую модель, отличающую живое лицо от плоской атаки, — и **установить границы её применимости**, доказав, где она работать не может.

2. Идея: параллакс

У живого лица есть рельеф: кончик носа вынесен вперёд относительно щёк. При движении головы это порождает **параллакс** — взаимное расположение точек в кадре меняется не так, как у плоского объекта.

Используются 6 опорных точек лица. Координата z — это **оценочная относительная псевдоглубина**, а не измеренная глубина.

$$IOD = d_{2D}(глаз_л, \quad глаз_п)$$
$$r_1 = [z_{нос} - (z_{щека\ л} + z_{щека\ п})/2] / IOD$$
$$r_2 = d_{2D}(нос, \quad глаз_л) / d_{2D}(нос, \quad глаз_п)$$
$$r_3 = d_{2D}(нос, \quad подбородок) / d_{2D}(щека_л, \quad щека_п)$$
$$G_k = Var_t[\quad r_k(t) \quad]$$
$$PLS = (G_1 + G_2 + G_3) / 3$$

Обучаемых весов в модели **нет**: только нормировка и порог, и оба оцениваются исключительно на обучающих участниках.

3. Как проверяли

- Субъект-дизъюнктная кросс-валидация** (LOSO): участник целиком либо в обучении, либо в тесте. Делить по кадрам — утечка данных.
- Метрики **APCER / BPCER / ACER** по ISO/IEC 30107-3.
- Протокол, гипотезы и правило выбора порога зафиксированы **до сбора данных**.
- Данные: **6 участников, 12 записей**. Видео не покидают компьютер; в репозитории только агрегированные числа.

4. Результат

Модель	APCER	BPCER	ACER
V0 мажоритарный	0.000	1.000	0.500
V1 статический 2D	0.333	0.167	0.250
M1 PLS (наша)	0.000	0.000	0.000

ЭТО НЕ «ТОЧНОСТЬ 100 %»

При нуле ошибок на 6 участниках **правило трёх** даёт верхнюю границу истинной вероятности ошибки **3/6 = 0.5**. Bootstrap выдал интервал [0.000, 0.000] — это **вырожденный** результат, а не доказательство безошибочности. Выборка мала, вывод разведочный.

0.250

ACER статического
однокадрового базлайна

0.000

ACER предложенной
модели PLS

5. Гипотеза не подтвердилась

Предполагалось (H2), что разделение обеспечивает G_1 — признак псевдоглубины носа. **Абляция это опровергла**:

Вариант модели	ACER
полный PLS ($G_1+G_2+G_3$)	0.000
без G_1 — псевдоглубины	0.000
без G_2 — асимметрии	0.083
без G_3 — пропорции	0.000

Удаление G_1 не меняет **ничего**. Портит результат только удаление G_2 — лево-правой асимметрии.

почему

Нормировка на межзрачковое расстояние **сокращает** множитель $\cos(\text{поворота})$ в числителе r_1 и глушит тот самый сигнал, ради которого признак вводился (доказано, утверждение 5).

Этот провал был предсказан симуляцией и записан в документацию до сбора данных. Формулировка гипотезы не менялась.

6. Доказанная граница: replay

Что если показать не фото, а **видео** поворачивающейся головы? Лицо на экране повернётся само.

УТВЕРЖДЕНИЕ 7

Неподвижный экран отображает кадр **гомотетией**: все попарные расстояния умножаются на одно число. Признаки r_2 и r_3 суть **отношения** расстояний — коэффициент сокращается.

Следствие: любой признак, построенный на отношениях двумерных расстояний, при такой атаке воспроизводится **тождественно**. Разделять нечего ни при каком пороге.

Проверено численно: $\max |r_2^{\text{живое}} - r_2^{\text{replay}}| = 0$. Совпадение побитовое, а не приближённое.

6%

фото на экране
принято за живое

100%

видео на экране
принято за живое

Модель не распознала **ни одной** атаки воспроизведением из 16. Гипотеза H4 о провале собственной модели зафиксирована в протоколе **до** эксперимента.

7. Выводы

- Доказаны **7 утверждений** о поведении модели; все подтверждены численно с точностью до 10^{-8} .
- Модель **точнее статического базлайна** на собранных данных, но выборка мала, и вывод разведочный.
- Разделение обеспечивает **не тот признак**, который предполагался, — и это было предсказано заранее.
- Доказана уязвимость **целого класса** признаков к replay-атакам. Защита от них требует признаков иной природы: измеряемой глубины, текстуры носителя или временной согласованности.

ЧЕГО РАБОТА НЕ УТВЕРЖДАЕТ

Не готовность к применению · не универсальную стойкость · не защиту от масок, дипфейков и печатных атак (класс не собирался) · не работу вне условий эксперимента: одна камера, одно освещение, 6 человек. Модель **не проверялась и не должна проверяться** против реальных систем контроля доступа.